

## İÇİNDEKİLER

<b>GİRİŞ.....</b>	<b>1</b>
<b>1. KULLANILAN ARAÇ VE YÖNTEMLER .....</b>	<b>2</b>
1.1. KDDCup99 Veri Setinin Detaylı Anlatımı.....	2
1.2. Saldırı Tipleri .....	5
1.2.1. Hizmet aksattırma saldırıları .....	5
1.2.2. U2R Saldırıları.....	6
1.2.3. R2L Saldırıları.....	6
1.2.4. Probing Saldırıları .....	6
1.3. Veri Setinin Hazırlanması .....	8
1.4. Kullanılan Ortam .....	11
1.4.1. Jupyter Notebook.....	11
1.5. Kullanılan Diller .....	11
1.6. Kullanılan Algoritma .....	11
1.6.1. K-NN Algoritması.....	11
<b>2. SONUÇ VE DEĞERLENDİRME .....</b>	<b>13</b>
<b>REFERANSLAR.....</b>	<b>15</b>

## GİRİŞ

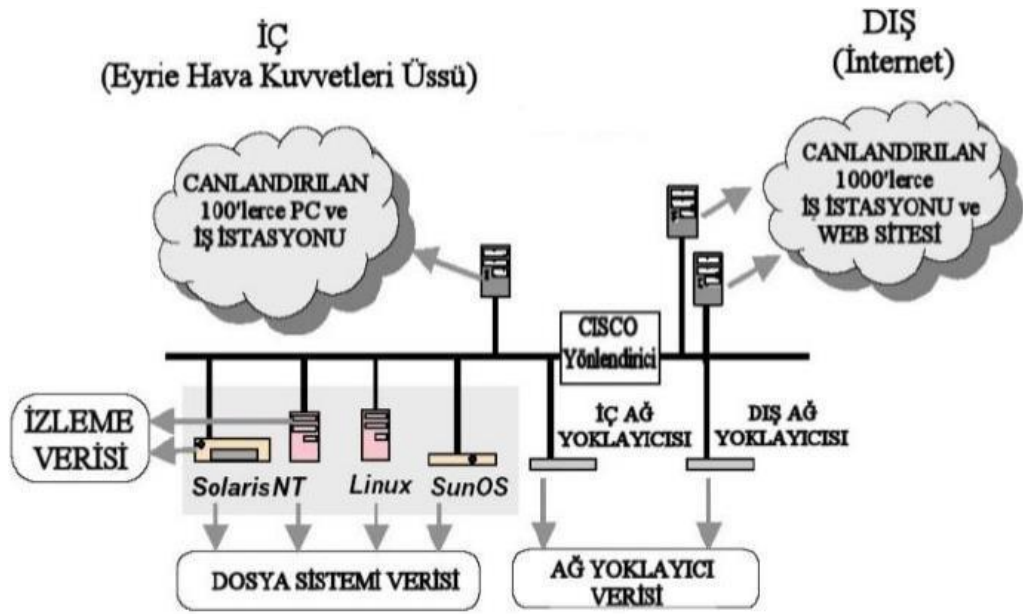
Yaşadığımız çağda şimdiye kadar hiç olmadığı kadar bilgi üretilmekte işlenmekte ve bunlara erişilmektedir. Bilginin bu denli hızlı üretilip yayılmasında hiç kuşkusuz bilgisayar teknolojileri en büyük teknik faydayı sağlamaktadır. Bilgiye erişim ve paylaşım için ise en fazla verimliliği bilgisayar ağları sağladığından, ağ işleyişinin düzgün olması hayati önem taşımaktadır. Ağ trafiğindeki anormallikler ise ağın gerektiği gibi kullanımını engelleyen unsurların başında gelmektedir. Bu anormallikler altyapı sorunlarından kaynaklanabileceği gibi ağın kötüye kullanılması veya ağa yapılan saldırılardan da kaynaklanabilmektedir [1]. Birçok kaynakta saldırı tespit sistemleri olarak da anılan anomali tespit sistemleri ağda oluşan düzensizlikleri tespit edip ilgili kişileri veya yazılımları uyarmayı sağlayan sistemlerdir.

Bu çalışmada büyük veri madenciliği tekniklerinden biri olan makine öğrenmesinin sınıflandırma algoritmalarından k-NN algoritması algoritması ile KDDCup99 veri seti üzerinde analizler yapılarak olası anomalilerin tespitinin analizi gerçekleştirilmiştir.

## 1. KULLANILAN ARAÇ VE YÖNTEMLER

### 1.1. KDDCup99 Veri Setinin Detaylı Anlatımı

Saldırı Tespit Sistemleriyle ilgili çalışmalarda en sık kullanılan veri seti DARPA 1998 ve 1999 veri setleridir. Biz de model oluşturma çalışmamızda yine bu verilerden türetilen KDD Cup'99 veri setini kullanacağız. Veri setini oluşturan kaynak aşağıdaki Şekil6'da da görüldüğü gibi saldırının hedefi olan bir iç ağ ve saldırıyı gerçekleştiren bir dış ağ olmak üzere iki farklı ağdan oluşmaktadır:



Şekil 1.1 Darpa Ağ Yapısı [3]

KDD'99 veri kümesi DARPA veri kümesinin bazı önışlemlerden geçirilmesiyle elde edilen 41 özelliğe sahip bir veri kümesidir. Bu veri kümesinin amacı diğer veri kümelerinde olduğu gibi farklı anomali tespit sistemlerinin eğitim ve test işlemlerini kolaylıkla gerçekleştirmek ve bu sistemlerin değerlendirilmesini sağlamaktır. DARPA ile her ne kadar anomali tespit sistemleri için veri kümesi probleminin çözülmesi adına önemli adımlar atılmışsa da KDD'99 ile eğitim ve test sonuçları çok daha hızlı alınabilmesi ve buna bağlı olarak anomali tespit sistemlerinin değerlendirilmesinin daha kısa sürede yapılabilmesi adına bu alanda atılmış önemli bir adımdır [2].

KDD'99 veri kümesi, 9 temel ve 32 adet türetilmiş olmak üzere toplam 41 özellikten oluşmaktadır. Bu 41 özellik aşağıdaki gibi 3 ana gruba ayrılmıştır:

-İçerik özellikleri (content features)

- Sunucu tabanlı trafik özellikleri (host-based traffic features)
- Zamana bağlı trafik özellikleri (time-based traffic features)

Çizelge 1.1, Çizelge 1.2 ve Çizelge 1.3’de, sırasıyla bu 3 grup ve gruplara ait veri özellikleri gösterilmiştir.

**Çizelge 1.1** İçerik özellikleri

Özellik Adı	Tanım	Tip
Duration	Bağlantı Uzunluğu	Sürekli
Protocol_type	Protokol Tipi	Ayrık
Service	Servis tipi	Ayrık
Src_bytes	Kaynaktan hedefe veri	Sürekli
Dst_bytes	Veri bayt sayısı	Sürekli
Flag	Bayrak	Ayrık
Land	Kaynak ve Hedef ip aynı ise 1 değil ise 0	Ayrık
Wrong_fragment	Yanlış parçalama	Sürekli
Urgent	Acil Paket sayısı	Sürekli

İçerik özellikleri, sadece TCP bağlantılarıyla ilgili olan özelliklerdir. Diğer gruplarda olduğu gibi ağdaki veriler üzerinde herhangi bir ön işlem yapılmasına gerek yoktur [2]. Sunucu tabanlı trafik özellikleri, etki alanı (domain) bilgisi ile ilgili içerik özellikleridir.

**Çizelge 1.2** Sunucu tabanlı trafik özellikleri

Özellik Adı	Tanım	Tip
Hot	“hot” göstergesi	Sürekli
Num_failed_logins	Hatalı giriş sayısı	Sürekli
Logged_in	Giriş başarılı ise 1 değil ise 0	Ayrık
Num_compromised	Gizliliğin ihlal edilme sayısı	Sürekli
Root_shell	“Root Shell” elde edildiyse 1 değilse 0	Ayrık
Su_attempted	“Su root” komutu girildiyse 1 değilse 0	Ayrık
Num_root	“root” erişim sayısı	Sürekli
Num_file_creations	Dosya oluşturma işlemleri sayısı	Sürekli
Num_shells	Shell promptlarının sayısı	Sürekli
Num_access_files	Kontrol dosyalarına erişim işlemleri sayısı	Sürekli
Num_outbound_cmds	ftp oturumunda giden komut sayısı	Sürekli
Is_hot_login	Giriş “hot” listesindeyse 1 değilse 0	Ayrık
Is_guest_login	Giriş “guest” ise 1 değilse 0	Ayrık

Zamana bağı trafik özellikleri, “aynı sunucu” ve “aynı servis” özelliklerine göre kullanılan özelliklerdir. “Aynı sunucu” özellikleri, son iki saniye içerisinde aynı sunucuya yapılan bağlantılardır, “aynı servis” özellikleri ise son iki saniye içerisinde aynı servise yapılan bağlantılardır [2].

**Çizelge 1.3** Zamana bağı trafik özellikleri

Özellik Adı	Tanım	Tip
Count	Aynı sunucuya önceki iki bağlantıyla aynı bağlantıların sayısı	Sürekli
Serror_rate	“SYN” hata bağlantılarının yüzdesi	Sürekli
Rerror_rate	“Rej” hata bağlantılarının yüzde	Sürekli
Same_srv_rate	Aynı servise bağlantıların yüzdesi	Sürekli
Diff_srv_rate	Farklı servislere bağlantıların yüzdesi	Sürekli
Srv_count	Aynı servise önceki iki bağlantıyla aynı bağlantıların sayısı	Sürekli
Srv_serror_rate	“SYN” hata bağlantılarının yüzdesi	Sürekli
Srv_rerror_rate	“Rej” hata bağlantılarının yüzdesi	Sürekli
Srv_diff_host_rate	Farklı servislere bağlantıların yüzdesi	Sürekli

## 1.2.Saldırı Tipleri

Bilgisayar sistemlerine yapılan saldırılar, birçok araştırmacı tarafından farklı gruplandırmalar yapılmıştır [4,5]. Saldırganların sürekli kendilerini yenilemeleri ve bilgisayar sistemlerindeki açıkları tespit etmeleri nedeniyle saldırı tiplerindeki çeşitlilik çok fazla artmıştır. MIT Lincoln Laboratuvarlarında yapılan bu çalışmalar sonucunda bilgisayar sistemlerine yapılan saldırılar kullandıkları yöntemlere göre dört ana gruba ayrılmış ve **DoS**, **U2R**, **R2L** ve **Probing** olarak adlandırılmıştır [6]. Bu saldırıların detaylı tanımları aşağıdaki başlıklarda sunulmuştur.

### 1.2.1. Hizmet aksattırma saldırıları

Hizmet aksattırma saldırıları olarak da bilinen DoS saldırıları sistemin hizmetlerini engellemek amacıyla yapılır. Bunu yapmak için sisteme cevap verebileceğinden çok daha fazla istek gönderilerek verilen hizmet aksattırılır. DoS saldırılarına örnek olarak SYN flood, Smurf, UDPstorm, Pingflood, Neptune, Mailbomb saldırıları verilebilir [7].

### 1.2.2. U2R saldırıları

U2R saldırıları sayesinde kullanıcılar normal yetkilere sahip olan kendi hesaplarından oturum açtıktan sonra yönetici yetkisine ulaşarak sistem üzerinde istedikleri bilgilere erişebilirler. En çok bilinen U2R saldırı tipleri Eject, Ffbconfig, Fdformat, Loadmodule, Perl gibi saldırılardır [7].

### 1.2.3. R2L saldırıları

Bu saldırı tipinde saldırgan saldırdığı makineye ağ üzerinden paketler yollayarak açıkları tespit etmeye çalışır. Bu konuda birçok araç olması ve bu araçlara kolay erişilebilir olması nedeniyle, sistemde var olan açıklar kapatılmamışsa etkili ve kolay bir saldırı yöntemidir. En çok bilinen R2L saldırı tiplerine Dictionary, Guest, Imap, Named, Sendmail gibi saldırılar örnek olarak verilebilir [7].

### 1.2.4. Probing saldırıları

Probing saldırıları, ağı veya bilgisayarı tarayarak zayıflıkları tespit etmek ve sistem yapısıyla ilgili genel bir bilgiye ulaşmak için yapılmaktadır. Bu tip saldırılarda önce sistem hakkında detaylı bilgi edinildikten sonra saldırının nasıl olacağı belirlenir. Bu saldırılar için kullanılan araçlar aynı zamanda güvenlik uzmanları tarafından sistemi güvenliğinin test edilmesi için de kullanılır. En çok bilinen Probe saldırı tipleri, Ipsweep, Mscan, Nmap, Saint, Satan gibi saldırılar örnek olarak verilebilir [7].

KDD'99 veri kümesi 38 farklı atak içermektedir. KDD'99 eğitim veri kümesinde bulunan 24 atak ve bu atakların ait oldukları saldırı tipleri ve saldırıları veri kümesinde bulunduran örnek sayıları Çizelge 1.4'de verilmiştir.

**Çizelge 1.4** KDD'99 veri kümesinin %10'luk kısmındaki saldırı örneklerinin sayıları

Saldırı	Örnek sayısı	Kategori
Smurf.	280790	DoS
Neptune.	107201	DoS
Back.	2203	DoS
Teardrop.	979	DoS
Pod.	264	DoS
Land.	21	Dos
Normal.	97277	Normal
Satan.	1589	Probe
Ipsweep.	1247	Probe
Portsweep.	1040	Probe
Nmap.	231	Probe
Warezclient.	1020	R2L

Guess_passwd	53	R2L
Warezmater	20	R2L
İmap.	12	R2L
ftp_write	8	R2L
Multihop.	7	R2L
Phf.	4	R2L
Spy.	2	R2L
Buffer_overflow	30	U2R
Rootkit.	10	U2R
Loadmodule	9	U2R
Perl	3	U2R

Sadece test veri kümesinde yer alan, eğitim kümesinde yer almayan ve etiketlenmiş KDD'99 dosyasından alınan 14 farklı atağa ait saldırı tipi ve örnek sayıları Çizelge 1.5'de sunulmuştur.

**Çizelge 1.5** Eğitim kümesinde yer almayan test veri kümesinde bulunan saldırılar

Saldırı	Örnek Sayısı	Kategori
Apache	794	DoS
Mailbomb	5000	DoS
Processtable	759	DoS
Udpstorm	2	DoS
Mscan	1053	Probe
Saint	736	Probe
Httpunnel	138	R2L
Named	17	R2L
Sendmail	17	R2L
Snmpgetattack	1040	R2L
Xlock	9	R2L
Xsnoop	4	R2L
Ps	16	U2R



```

Data columns (total 42 columns):
duration          494021 non-null int64
protocol_type     494021 non-null object
service          494021 non-null object
flag             494021 non-null object
src_bytes        494021 non-null int64
dst_bytes        494021 non-null int64
land             494021 non-null int64
wrong_fragment   494021 non-null int64
urgent           494021 non-null int64
hot              494021 non-null int64
num_failed_logins 494021 non-null int64
logged_in        494021 non-null int64
num_compromised  494021 non-null int64
root_shell       494021 non-null int64
su_attempted     494021 non-null int64
num_root         494021 non-null int64
num_file_creations 494021 non-null int64
num_shells       494021 non-null int64
num_access_files 494021 non-null int64
num_outbound_cmds 494021 non-null int64
is_host_login    494021 non-null int64
is_guest_login   494021 non-null int64
count            494021 non-null int64
srv_count        494021 non-null int64
serror_rate      494021 non-null float64
srv_serror_rate  494021 non-null float64
rerror_rate      494021 non-null float64
srv_rerror_rate  494021 non-null float64
same_srv_rate    494021 non-null float64
diff_srv_rate    494021 non-null float64
srv_diff_host_rate 494021 non-null float64
dst_host_count   494021 non-null int64
dst_host_srv_count 494021 non-null int64
dst_host_same_srv_rate 494021 non-null float64
dst_host_diff_srv_rate 494021 non-null float64
dst_host_same_src_port_rate 494021 non-null float64
dst_host_srv_diff_host_rate 494021 non-null float64
dst_host_serror_rate 494021 non-null float64
dst_host_srv_serror_rate 494021 non-null float64
dst_host_rerror_rate 494021 non-null float64
dst_host_srv_rerror_rate 494021 non-null float64
label            494021 non-null object
dtypes: float64(15), int64(23), object(4)

```

**Şekil 1.2.** Verisetindeki özellikler ve tipleri

### 1.3. Veri Setinin Hazırlanması

Çalışmamda “kddcup.data\_10\_percent\_corrected” dosya ismi ile internetten indirilebilen yaklaşık 75Mb büyüklüğünde ve içinde 494021 kayıt bulunan gerçek kddCupp-99 veri seti’nin 10%’una karşılık gelen veri seti kullanıldı. Veri setinde toplam 41 adet özellik bulunmaktadır.

Verisetinin daha anlamlı hale gelmesi için özellik seçmesi yapılmasına karar verilmiştir ve özellik seçimi yaparken literatür taramasında bulduğum “Lojistik Regresyon ile Bilgisayar Ağlarında Anomali Tespiti” adlı makale göz önüne alınmıştır. Makaleye göre aşağıdaki prensiplere uyarak bu sayıyı 9’a indirilmiştir:

-Parametrelerin birbirlerinden bağımsız olanları seçilmiştir. Örneğin root\_shell, su\_attempted, num\_root alanlarının tümü birden alınmak yerine su\_attempted alanı alınmıştır.

-Parametrelerin bağımlı değişkeni etkilemeyecek olanları seçilmemiştir.

-Veriler daha kolay işlenebilmek için binary hale getirilmiştir.

Bu prensiplere uyarak özellik olarak aşağıda sıralanan özellikleri kullanılmıştır.

- **protocol\_type**
- **service**
- **flag**

- land
- wrong\_fragment
- hot
- um\_failed\_logins
- nsu\_attempted
- num\_access\_files

	Missing Records	Percentage (%)
duration	0	0.0
protocol_type	0	0.0
service	0	0.0
flag	0	0.0
src_bytes	0	0.0
dst_bytes	0	0.0
land	0	0.0
wrong_fragment	0	0.0
urgent	0	0.0
hot	0	0.0
num_failed_logins	0	0.0
logged_in	0	0.0
num_compromised	0	0.0
root_shell	0	0.0
su_attempted	0	0.0
num_root	0	0.0
num_file_creations	0	0.0
num_shells	0	0.0
num_access_files	0	0.0
num_outbound_cmds	0	0.0
is_host_login	0	0.0
is_guest_login	0	0.0
count	0	0.0
srv_count	0	0.0
error_rate	0	0.0
srv_error_rate	0	0.0
rerror_rate	0	0.0

Şekil 1.3. Eksik veri kontrol sonucu

Özellik seçiminden sonra verisetinden eksik veri olup olmadığı kontrol edilmiş ve Şekil 1.3’ te görüldüğü gibi eksik veri bulunmamaktadır.

Verinin ön işleme aşamasında verisetinin ölçeklenmesi de önemlidir. Veri ölçekleme, mevcut konumu ve yönü bozulmadan büyütüp küçültmek, veriyi algoritmanın daha iyi anlayabileceği şekle getirmek, veriyi daha iyi ifade etmeyi sağlamaktadır. Bu çalışmada ölçekleme olarak pratikte fazlasıyla kullanılan **standardizasyon** yöntemi tercih edilmiştir. Böylece, verisetindeki her feature için ortalaması 0, varyansı 1 yapar ve tüm özelliklerin aynı büyüklüğe olmasını sağlar, veriyi sıkıştırır.

	protocol_type	service	flag	land	wrong_fragment	hot	num_failed_logins
0	tcp	http	SF	0	0	0	0
1	tcp	http	SF	0	0	0	0
2	tcp	http	SF	0	0	0	0
3	tcp	http	SF	0	0	0	0
4	tcp	http	SF	0	0	0	0

Şekil 1.4. Verisetindeki kategorik verilerin bir kısmı

```
In [40]: dataset['flag'].value_counts()
```

```
Out[40]: SF      378440
        SO      87007
        REJ     26875
        RSTR      903
        RSTO      579
        SH       107
        S1        57
        S2        24
        RSTOSO     11
        S3        10
        OTH        8
        Name: flag, dtype: int64
```

Şekil 1.5. Flag özelliğine ait farklı verileri

```
In [38]: dataset['service'].value_counts()
```

```
Out[38]: ecr_i      281400
        private  110893
        http     64293
        smtp     9723
        other    7237
        domain_u 5863
        ftp_data 4721
        eca_i    1642
        ftp      798
        finger   670
        urp_i    538
        telnet   213
        ntp_u    380
        auth     328
        pop_3    202
        time     157
        csnet_ns 126
        remote_job 120
        gopher   117
        imap4    117
        domain   116
        discard  116
        systat   115
        iso_tsap 115
        shell    112
        echo     112
        rje      111
        sql_net  110
        whois    110
        printer  109
        ...
        klogin   106
        bgp      106
        vmnet    106
        uucp_path 106
        supdup   105
        ssh      105
        rnap     105
        login    104
        hostnames 104
        efs      103
        daytime  103
        netbios_ns 102
        link     102
        pop_2    101
        ldap     101
        exec     99
        http_443 99
        netbios_dgm 99
        name     98
        kshell   98
        ctf      97
        netstat  95
        Z39_50   92
        IRC      43
        urh_i    14
        X11      11
        rlm_i    7
        tftp_u   1
        rrd_i    1
        pm_dump  1
        Name: service, Length: 66, dtype: int64
```

Şekil 1.6. service özelliğine ait farklı verileri

```
In [37]: dataset['protocol_type'].value_counts()
```

```
Out[37]: icmp  283602
        tcp    190065
        udp    20354
        Name: protocol_type, dtype: int64
```

Şekil 1.7. protocol\_type özelliğine ait farklı verileri

Şekil 1.5. , Şekil 1.6. , Şekil 1.7.' te görüldüğü gibi flag, protocol\_type, service özelliklerinin verileri sayısal değil yani kategorik veriler olarak adlandırılmaktadır. Bu durum, makine öğrenmesi algoritmaları matematiğe dayalı çalıştığından sayısal olması gerekmektedir. Bundan dolayı bu özelliklere ait veriler LabelEncoder yöntemi ile sayısal verilere çevrilmiştir.

	protocol_type	service	flag	land	wrong_fragment	hot
0	1	22	9	0	0	0
1	1	22	9	0	0	0
2	1	22	9	0	0	0
3	1	22	9	0	0	0
4	1	22	9	0	0	0
5	1	22	9	0	0	0
6	1	22	9	0	0	0
7	1	22	9	0	0	0
8	1	22	9	0	0	0
9	1	22	9	0	0	1
10	1	22	9	0	0	0
11	1	22	9	0	0	0
12	1	22	9	0	0	0
13	1	22	9	0	0	0
14	1	22	9	0	0	0
15	1	22	9	0	0	0
16	1	22	9	0	0	0
17	1	22	9	0	0	0
18	1	22	9	0	0	0

Şekil 1.8. Kategorik veriler sayısal verilere çevrildikten sonraki hali

Verisetimizi modele uygun hale getirmek için projenin ilk aşamasında eğitim verisi %70, test verisi %30 olarak parçalanmıştır ve eğitim verileri ile eğitim aşaması tamamlanıp model oluşturulmuştur. İkinci aşamasında, k-fold Cross Validation yöntemi ile tüm veri 3 ile 10 parçaya bölünerek teker teker her parça üzerinden eğitim ve test verisi olarak kullanılarak değerlendirilmiştir.

## 1.4. Kullanılan Ortam

### 1.4.1. Jupyter Notebook

Jupyter Notebook aldığımız notları ve hesaplamaları beraber tutmak için , Python kodları yazma olanağı sağlayan, görselleştirme özelliği bulunan yararlı bir araçtır.

## 1.5. Kullanılan Diller

Bu çalışmada **Python** programlama dili kullanılmıştır. Python, nesne yönelimli, yorumlamalı, birimsel ve etikelişimli yüksek seviyeli bir programlama dilidir.

## 1.6. Kullanılan Algoritma

### 1.6.1. K-NN Algoritması

Makine öğrenmesi algoritmaları arasında en basiti olarak belirtilmektedir. Modeli oluşturmak, yalnızca eğitim datasetinin saklanmasıyla oluşur. Yeni bir veri noktası için bir tahmin yapmak için algoritma, eğitim verisetindeki “en yakın komşuları” içindeki en yakın veri noktalarını bulur. Çoğunluk olan taraf seçilir. Öngöründe bulunmak istediğimiz noktaya en yakın eğitim verilerini dikkate alır. Bütün eğitim seti içindekiler ile arasındaki uzaklık bulunur. En yakın k

örnek seçilir. Hem classifivation hem regression için kullanılır. Bu çalışmada, problem sınıflandırma problemi olduğu için K-NN algoritması sınıflandırma amaçlı kullanılmıştır.

## 2. SONUÇ VE DEĞERLENDİRME

Bu çalışmada, KDD Cup'99 veri kümeleri kullanılarak büyük veri madenciliğinin sınıflandırma tekniklerinden olan k-NN tekniği algoritması ile bilgisayar ağlarında alışılmışın dışında bir durum olup olmadığı hakkında analizler yapılmış ve bu analizlerin nasıl gerçekleştirildiği üzerinde durulmuştur.

Modelin başarısını ölçerken confusion matrix diye adlandırılan karışıklık matrisinden yararlanılır. Confusion matrix, gerçek değerlerin bilindiği test verisi üzerinde bir sınıflandırma modelinin doğruluğunu, performansını ölçmek için kullanılmaktadır. Çalışmada doğruluk ölçümü doğruluk oranı  $(TP+ TN) / \text{Toplam}$  formülüne dayanarak bulunmuştur [8].

TAHMİN EDİLEN DEĞERLER	GERÇEK DEĞERLER		
		POZİTİF	NEGATİF
	POZİTİF	Gerçek Pozitif True Positive – TP	Sahte Pozitif False Positive – FP
	NEGATİF	Sahte Negatif False Negative – FN	Gerçek Negatif True Negative – TN


Şekil 2.1. Karışıklık matrisi

k-NN algoritmasında parametre olarak en yakın komşu sayısı “k” değeri belirleniyor. Bu çalışmada k değerine 1’den 30’ a kadar değerler verilmiştir. Çalışma sonucundaki modelin doğruluk ya da başarı oranı şekil 2.2’ de görülmektedir. Şekilden de anlaşılabileceği üzere k parametresinin değeri arttıkça modelimizin başarısı ufak tefek artıp azalma göstermektedir. En yüksek başarı oranı k= 3 iken %0.994473 olarak sonuçlanmıştır ve son olarak k=26 değerinde %0.993993’ te sabitlenmiştir.

k=1 0.9863703558306293	k=13 0.9863703558306293
k=2 0.9865298386156894	k=14 0.994135940672404
k=3 0.9944733081023389	k=15 0.9941114048593178
k=4 0.9942954234574641	k=16 0.9940991369527747
k=5 0.994418102522895	k=17 0.9942586197378348
k=6 0.9942463518312917	k=18 0.9942770215976495
k=7 0.9942402178780202	k=19 0.9942708876443779
k=8 0.9942218160182056	k=20 0.9942647536911063
k=9 0.9942095481116625	k=21 0.994215682064934
k=10 0.9941911462518479	k=22 0.9942095481116625
k=11 0.9941911462518479	k=23 0.9940991369527747
k=12 0.9941604764854901	k=24 0.9940991369527747
	k=25 0.9940746011396885
	k=26 0.9939948597471584
	k=27 0.9939948597471584
	k=28 0.9939948597471584
	k=29 0.9939948597471584
	k=30 0.9939948597471584

Şekil 2.2. Modelin başarı oranlarının çıktıları

Şekil 2.3 ' te modelin başarısının grafiksel olarak gösterilmektedir.



**Şekil 2.3.** Modelin başarı oranlarının grafiksel hali

Model iyi bir başarı göstermektedir. Model, güvenlik seviyesi çok yüksek olması gereken ve yanlış alarmlarla uğraşacak yeterli elemanı olan, kritik öneme sahip ağ işletim merkezleri için uygundur.

Bu çalışmada başvuru KDD Cup'99 veri kümesi yaygın olarak şimdiki saldırı tespit sistemlerinde kullanılmakta ama bu 1999'un verisi olduğu için ve ağ teknolojileri ve saldırı metotları sürekli değiştiğinden bu, şimdiki gerçek ağ durumunu yansıtamayabilir. Bu yüzden gelecekte yapılacak çalışmalarda, günümüzdeki ağ durumunu daha doğru bir şekilde yansıtabilmek için daha yeni bilgiye sahip olunup, test edilip ve kıyaslama yapılması önerilmektedir. Bu çalışmada karşılaşılan güçlük olarak toplanan verilerin işlenmesinin uzun sürmesi olarak söylenebilir.

## REFERANSLAR

1. Budak, İ, Şen, B ve Yıldırım, M.Z., “Lojistik regresyon ile bilgisayar ağlarında anomali tespiti”, XIII. Akademik Bilişim Konferansı, Antalya (2013).
2. Güven, E. N., “Zeki saldırı sistemlerinin incelenmesi, tasarımı ve gerçekleştirilmesi”, Yüksek Lisans Tezi, Gazi Üniversitesi Fen Bilimleri Enstitüsü, 1-91 (2007).
3. M. A. Aydın, “Bilgisayar Ağlarında Saldırı Tespiti için İstatistiksel Yöntem Kullanılması”, İTÜ Yüksek Lisans Tezi, 2005.
4. Cabrera, B.D., Cabrera, L. Lewis and R.K. Mehra, “Detection and classification of intrusions and faults using sequence of system calls”, ACM SIGMOD record, 30(4): 25-34 (2001).
5. Bace, R., Mell, P., “Intrusion detection systems”, Technical Report, National Institute of Standards and Technology, NIST SP300-31, Scotts Valley, CA, 5-46 (2001).
6. İnternet: Massachusetts Teknoloji Enstitüsü Lincoln Laboratuvarları “Off-line intrusion detection evaluation data” <http://www.ll.mit.edu/IST/ideval/> (2009).
7. Mukkamala, S., Janoski, G., Sung, A., “Intrusion detection using neural networks and support vector machines”, IEEE International Joint Conference on Neural Networks, IEEE Computer Society Press, 1702-1707 (2002).
8. İnternet: <https://veribilimcisi.com/2017/07/18/karisiklik-matrиси-nedir/>(Erişim Tarihi: 24.12.2018)